Requerimientos funcionales y no funcionales de Catalina

Explicación del alcance y criterios de aceptación

Documento de apoyo al trabajo de grado
Fecha de revisión 4 de noviembre de 2026

Propósito y alcance

Este documento explica los 15 requerimientos funcionales y los 10 no funcionales suministrados para Catalina, conservando sus identificadores y prioridades. Describe qué significa cada uno en el prototipo, cómo se materializa y qué debe verificarse para aceptarlo. Distingue capacidades implementadas de cobertura parcial y trabajo pendiente para evitar atribuir al sistema funciones que no están demostradas.

La revisión se basa en el código local, contratos de la API y evidencias conservadas de ensayos del sistema. Es una explicación técnica del estado observado, no un acta formal de aceptación ni una nueva ejecución completa de las pruebas. Las rutas de código del documento se expresan respecto de services/ingestion/src/catalina_ingestion, salvo cuando se indica frontend, scripts o evidence.

Cómo interpretar las fichas

Un requerimiento funcional define una capacidad que el sistema ofrece a un actor. Uno no funcional establece condiciones de calidad o de operación. La prioridad Alta o Media corresponde a la lista entregada y no representa un resultado de prueba. El estado indica el alcance observado; los criterios de aceptación describen cómo comprobarlo y no implican que todos hayan sido auditados.

Los visitantes reciben orientación pública. Los usuarios autenticados acceden a documentos, historial y directorio del campus. Las operaciones de administración documental requieren un rol con permisos. La interfaz conversacional no sustituye una consola administrativa completa.

Hallazgos que afectan la interpretación

- La clasificación documental existe como asignación y validación de categorías configuradas; no se identificó un catálogo administrable completo.
- Las preguntas sugeridas y respuestas públicas están disponibles, pero no se identificó un módulo independiente de administración de preguntas frecuentes.
- La recuperación y los controles de fundamentación están implementados; el rendimiento global, la seguridad integral y la calidad factual de todas las respuestas requieren evaluaciones adicionales.

RF-01 Consulta mediante lenguaje natural

Prioridad Alta | **Estado** Implementado

Explicación. Permite escribir preguntas en español con expresiones habituales, sin aprender comandos o consultas de base de datos. El usuario envía el texto desde el chat y Catalina identifica si corresponde a orientación pública, conversación, documentos o ubicaciones.

Aplicación en Catalina. Intervienen el visitante o usuario autenticado, la interfaz React y el servicio de conversación. El formulario valida texto vacío y longitud; el backend valida nuevamente la consulta. Las consultas documentales y las ubicaciones requieren sesión.

Criterio de aceptación. Enviar una pregunta válida debe producir una respuesta o un mensaje controlado de error. Una pregunta vacía debe rechazarse. La entrada no puede habilitar funciones restringidas por incluir instrucciones dentro del texto.

Alcance y limitaciones. La interfaz admite preguntas de hasta 1000 caracteres. Comprender lenguaje natural no garantiza entender cualquier ambigüedad o mantener un contexto ilimitado. Ejemplo: ¿Dónde puedo hacer trámites de Psicología?

Referencias de implementación. frontend/web/src/App.tsx; api/routes/answers.py; services/chat.py.

RF-02 Consulta de información institucional

Prioridad Alta | **Estado** Implementado con alcance delimitado

Explicación. Orienta sobre información de la Universidad Católica de Colombia incluida en las fuentes y contenidos configurados. Abarca la presentación de Catalina, oferta pública de pregrado, admisiones y consultas institucionales respaldadas por el corpus.

Aplicación en Catalina. Antes de iniciar sesión se ofrece contenido público curado y enlaces oficiales. Las preguntas sobre precios remiten a Registro y Control sin cotizar valores no verificados. Con sesión se habilita la consulta documental y del directorio.

Criterio de aceptación. Las preguntas públicas previstas deben ofrecer orientación coherente; una consulta fuera de ese alcance debe pedir autenticación. Una consulta documental solo debe usar evidencia disponible o abstenerse.

Alcance y limitaciones. No equivale a consultar en tiempo real toda la web universitaria. La oferta pública se configura y debe revisarse cuando cambie; tampoco reemplaza la asesoría de Admisiones. Ejemplo: ¿Dónde me puedo matricular?

Referencias de implementación. services/public_assistance.py; services/chat.py; api/routes/answers.py.

RF-03 Consulta de información académica

Prioridad Alta | **Estado** Implementado con cobertura del corpus

Explicación. Permite consultar fechas del calendario y procedimientos académicos publicados, como la solicitud de certificados y constancias. El dato debe diferenciar año, semestre y duración del programa cuando esas variables alteran la respuesta.

Aplicación en Catalina. El usuario autenticado pregunta y el sistema recupera fragmentos. Los extractores de calendario leen filas reconocibles de la tabla; el de certificados conserva el procedimiento recuperado de Registro y Control Académico.

Criterio de aceptación. Al preguntar por el fin de clases del segundo semestre de 2026, debe distinguir 16 semanas y 17 semanas y mostrar la fuente. Si falta el semestre, debe aclararlo en el caso soportado; no debe reutilizar fechas de 2026 para otro año.

Alcance y limitaciones. En el ensayo se recuperaron el 21 y 28 de noviembre de 2026, respectivamente. No todas las formulaciones recuperaron bien el segundo corte o el cierre del sistema; esos casos no se consideran cubiertos por la demostración.

Referencias de implementación. services/calendar_dates.py; services/procedure_excerpt.py; evidence/video-demo/respuesta-fechas-real.json.

RF-04 Consulta de reglamentos y documentos institucionales

Prioridad Alta | **Estado** Implementado

Explicación. Permite localizar información dentro del Reglamento del Estudiante y otros documentos registrados. Incluye identificar el documento pertinente, consultar temas de su estructura y recuperar pasajes respaldados por una versión.

Aplicación en Catalina. La consulta autenticada entra al servicio RAG. Según su naturaleza, la respuesta puede ser una vista del índice, un extracto, un identificador documental o una redacción generada y verificada.

Criterio de aceptación. Una consulta soportada sobre el reglamento debe recuperar el documento y la versión esperados y presentar sus citas. Si el fragmento no respalda la conclusión, el sistema debe evitar afirmarla o abstenerse.

Alcance y limitaciones. El corpus evaluado contiene el Reglamento del Estudiante 406-2026. Una vista del índice no prueba el contenido de un artículo: los requisitos o sanciones específicos necesitan pasajes pertinentes. La vigencia se interpreta según las versiones activas registradas.

Referencias de implementación. services/document_overview.py; services/document_excerpt.py; services/answer_generation.py.

RF-05 Consulta de dependencias universitarias

Prioridad Alta | Estado Implementado con directorio orientativo

Explicación. Permite identificar facultades, oficinas y servicios registrados y conocer su sede. Su propósito es orientar al usuario hacia una dependencia apropiada sin inventar oficinas, horarios o procedimientos que no estén verificados.

Aplicación en Catalina. Con sesión, Catalina detecta la intención de ubicación y busca nombres o alias del directorio. La orientación de trámites académicos de Psicología señala la facultad y pide confirmar el área y requisitos del trámite específico.

Criterio de aceptación. Una dependencia registrada debe devolver su nombre y contexto de sede; si no existe una ubicación confirmada, debe indicarlo. Las consultas del directorio sin token deben rechazarse.

Alcance y limitaciones. No todos los trámites de un estudiante de Psicología se resuelven en la facultad. La orientación académica no debe confundirse con la atención clínica de servicios psicológicos. Ejemplo: ¿Dónde puedo hacer trámites de Psicología?

Referencias de implementación. services/campus.py; api/routes/campus.py; data/campus_locations.json.

RF-06 Consulta de ubicación de espacios físicos

Prioridad Alta | Estado Implementado como mapa de referencia

Explicación. Representa sedes y dependencias en un plano interactivo del campus. Relaciona la pregunta con marcadores, ofrece una ficha de ubicación y permite acercar o restablecer la vista del mapa.

Aplicación en Catalina. El usuario autenticado pregunta por un espacio o selecciona un marcador. Una respuesta de ubicación puede abrir el mapa con el lugar identificado. El plano conserva números de referencia y nombres mediante interacción.

Criterio de aceptación. La biblioteca de Sede 4 y el auditorio deben señalar su ubicación registrada. Una consulta ambigua debe ofrecer opciones. El zoom debe funcionar sin permitir desplazamientos desordenados del plano.

Alcance y limitaciones. El plano es orientativo y utiliza coordenadas de la imagen, no un sistema de navegación GPS. Algunos accesos, pisos y oficinas requieren confirmación. La portada muestra una vista previa del plano; no debe calificarse como archivo confidencial.

Referencias de implementación. frontend/web/src/CampusMap.tsx; services/campus.py; data/campus_locations.json.

RF-07 Recuperación de información mediante RAG

Prioridad Alta | **Estado** Implementado y evaluado en conjunto controlado

Explicación. Recupera fragmentos pertinentes del corpus para construir el contexto que respalda una consulta. RAG combina recuperación documental con la elaboración posterior de una respuesta; no significa que el modelo haya sido reentrenado con esos documentos.

Aplicación en Catalina. La consulta se representa mediante embeddings; Qdrant busca candidatos y el pipeline aplica selección, umbrales y controles de evidencia. PostgreSQL permite resolver documentos y ejecuciones activas.

Criterio de aceptación. La recuperación debe devolver contexto con fuentes trazables cuando exista evidencia suficiente y deshabilitarlo cuando no la haya. Solo deben utilizarse documentos y ejecuciones admitidos por la política activa.

Alcance y limitaciones. La corrida del 28 de octubre evaluó 20 consultas y cumplió los criterios del script en todas. Ese resultado no equivale a exactitud universal ni evalúa la redacción de Ollama. La colección es documentos_universidad, con embeddings de 768 dimensiones.

Referencias de implementación. services/retrieval_runtime.py; services/vector_search.py; scripts/evaluate_grounded_rag_challenge.py.

RF-08 Generación de respuestas fundamentadas

Prioridad Alta | **Estado** Implementado con verificación y límites

Explicación. Exige que las afirmaciones institucionales estén apoyadas en la evidencia recuperada. Cuando corresponde generar texto, Ollama recibe un contexto delimitado y las citas permitidas; el resultado pasa por controles de fundamentación.

Aplicación en Catalina. El orquestador puede usar generación, extracción literal, identificación documental o directorio. La generación dispone de verificación y una ruta de corrección o rechazo; las respuestas extractivas conservan la fuente.

Criterio de aceptación. Una respuesta documental debe mantener correspondencia entre sus afirmaciones y las citas utilizadas. Ante verificación fallida no debe mostrarse una conclusión como si estuviera respaldada. La evaluación debe incluir revisión factual humana.

Alcance y limitaciones. Los controles reducen riesgos, pero no prueban ausencia de alucinaciones. No todas las respuestas de la demostración son generadas por Ollama y la evaluación de recuperación no sustituye medir fidelidad de respuestas finales.

Referencias de implementación. services/answer_generation.py; services/generation_verifier.py; services/prompt_builder.py.

RF-09 Visualización de fuentes documentales

Prioridad Alta | **Estado** Implementado con limitación en historial

Explicación. Permite abrir las referencias de una respuesta documental para identificar documento, versión, página o sección cuando están disponibles. La visualización ayuda a contrastar el contenido de la respuesta.

Aplicación en Catalina. El backend devuelve citas estructuradas y la interfaz las presenta en Consultar fuentes. El usuario puede revisar cada referencia sin confundirla con una fuente de una consulta diferente.

Criterio de aceptación. Una respuesta documental con citas debe mostrar el nombre del documento y la versión; debe añadir página y sección si existen. Una respuesta sin evidencia no debe fabricar referencias.

Alcance y limitaciones. Las citas de respuestas recientes se guardan también en memoria del frontend. El historial recargado puede no devolver esas citas en su contrato actual; la interfaz avisa cuando no están disponibles. Mostrar una cita no implica ofrecer un visor de PDF en la página.

Referencias de implementación. frontend/web/src/App.tsx componente Sources; api/routes/answers.py; api/routes/conversations.py.

RF-10 Gestión de documentos institucionales

Prioridad Alta | **Estado** Implementado mediante API administrativa

Explicación. Permite incorporar y consultar documentos con metadatos, archivo de origen y estado de procesamiento. La gestión documental alimenta el corpus utilizado por el servicio de consulta.

Aplicación en Catalina. Un administrador autenticado registra el archivo, código, nombre, categoría y versión. El servicio valida el archivo y los metadatos, recibe el contenido en almacenamiento y registra el trabajo de ingesta.

Criterio de aceptación. Una carga válida debe producir identificadores de documento, versión y trabajo. Un archivo o metadato no admitido debe rechazarse con un error controlado. Un usuario sin permisos no debe efectuar operaciones administrativas.

Alcance y limitaciones. La capacidad se identifica en el backend y en sus contratos de FastAPI. No se da por implementada una consola gráfica completa de administración en el frontend conversacional. Tampoco implica editar libremente el contenido de un PDF desde la aplicación.

Referencias de implementación. api/routes/documents.py; services/document_admin.py; services/document_registration.py.

RF-11 Versionamiento documental

Prioridad Alta | **Estado** Implementado en el flujo de ingesta

Explicación. Conserva versiones diferentes de un documento y permite asociar cada respuesta recuperada con la versión utilizada. Se distingue el documento lógico de sus archivos y procesamientos posteriores.

Aplicación en Catalina. El administrador registra una nueva versión del documento existente. Cada versión tiene hash, metadatos y estado; la indexación produce una ejecución vinculada. La activación se realiza tras las validaciones del flujo.

Criterio de aceptación. La versión nueva debe permanecer asociada al documento correcto y tener su propia identidad. La recuperación debe usar la versión activa admitida. Un fallo previo a la activación no debe convertir una indexación incompleta en evidencia vigente.

Alcance y limitaciones. El control de versiones del corpus no demuestra por sí mismo vigencia jurídica completa. Debe existir una revisión de la norma aplicable y de sus modificaciones. No confundir la versión del documento con una rama Git.

Referencias de implementación. api/routes/documents.py registro de versiones; repositories/documents.py; services/qdrant_indexing.py.

RF-12 Reindexación documental

Prioridad Alta | **Estado** Implementado mediante API administrativa

Explicación. Permite volver a procesar e indexar una versión admitida sin registrar necesariamente otro documento lógico. Resulta útil cuando se necesita reconstruir sus fragmentos o corregir un procesamiento.

Aplicación en Catalina. El administrador solicita la reindexación de la versión; se registra el trabajo y una nueva ejecución. El flujo genera embeddings, verifica la indexación y actualiza la ejecución activa según sus reglas.

Criterio de aceptación. La solicitud autorizada debe producir un trabajo rastreable. No debe publicarse una ejecución incompleta como activa. El reintento de un trabajo debe respetar sus estados y evitar asociaciones cruzadas entre versiones.

Alcance y limitaciones. El servicio actual exige que la versión solicitada para reindexar esté activa. La ruta de reintentos y la de reindexación son operaciones distintas. Cambiar modelo o dimensión puede requerir una migración adicional de colección, no solo pulsar reindexar.

Referencias de implementación. api/routes/job_control.py; services/job_control.py; services/qdrant_indexing.py.

RF-13 Registro del historial de conversaciones

Prioridad Media | Estado Implementado

Explicación. Conserva conversaciones y mensajes del usuario autenticado para retomarlos posteriormente. La organización incluye crear, listar, renombrar y eliminar conversaciones propias.

Aplicación en Catalina. Al enviar una consulta con sesión se utiliza o crea una conversación y se registra el intercambio. El usuario puede abrir otra, buscar por título y regresar a una conversación anterior.

Criterio de aceptación. Los mensajes guardados deben corresponder a la conversación y al usuario correctos. Un usuario no debe acceder al historial de otro. La eliminación debe requerir la acción prevista en la interfaz.

Alcance y limitaciones. El chat público no crea un historial personal persistente de la misma manera. Además, las fuentes detalladas de mensajes antiguos pueden no estar disponibles tras recargar la sesión; esa limitación se relaciona con RF-09 y RNF-08.

Referencias de implementación. api/routes/conversations.py; services/conversation_answers.py; frontend/web/src/api.ts.

RF-14 Gestión de categorías documentales

Prioridad Media | Estado Parcial

Explicación. Organiza documentos por categorías como reglamentos, académico, administrativo, bienestar, sedes o facultades. La clasificación permite mantener un corpus ordenado y validar la información registrada.

Aplicación en Catalina. El administrador asigna una categoría al registrar el documento. El backend normaliza el valor y comprueba que pertenezca al listado permitido en la configuración.

Criterio de aceptación. Una categoría permitida debe conservarse en el registro; una categoría no admitida debe rechazarse. Para hablar de gestión completa, se requeriría crear, editar o desactivar categorías mediante una operación administrativa controlada.

Alcance y limitaciones. Actualmente se observa asignación y validación de categorías configuradas. No se identificó un módulo independiente de catálogo con operaciones de alta, modificación y baja de categorías. Esa parte del requerimiento permanece pendiente.

Referencias de implementación. core/config.py allowed_categories; schemas/documents.py; services/document_registration.py.

RF-15 Gestión de preguntas frecuentes

Prioridad Media | Estado Parcial con administración pendiente

Explicación. Busca administrar preguntas y respuestas frecuentes para orientar consultas repetidas. Una gestión completa debe permitir mantener su contenido, estado, alcance público o autenticado y, cuando proceda, fuente o fecha de revisión.

Aplicación en Catalina. Catalina dispone de sugerencias en la interfaz y respuestas públicas curadas para presentación, admisiones, carreras y precios. Además, la configuración admite la categoría documental faq.

Criterio de aceptación. Las sugerencias deben insertar preguntas coherentes y las respuestas públicas respetar el alcance autorizado. Para aprobar el requisito como módulo de gestión, un administrador debería poder crear, modificar y desactivar preguntas frecuentes sin editar código.

Alcance y limitaciones. No se identificó una entidad o API independiente de preguntas frecuentes con esas operaciones. La categoría faq, los saludos directos y una lista de preguntas sugeridas no equivalen a ese módulo completo.

Referencias de implementación. services/public_assistance.py; frontend/web/src/App.tsx; core/config.py.

RNF-01 Fundamentación en información institucional

Prioridad Alta | Estado Controles implementados y evaluación parcial

Explicación. Define una condición de calidad: las afirmaciones institucionales deben derivarse de fuentes pertinentes y reconocibles, en lugar de presentarse como conocimiento no comprobado del modelo.

Aplicación en Catalina. Se apoya en recuperación, filtros de evidencia, selección de versiones activas, prompts acotados y verificación. La orientación pública utiliza contenido curado y referencias oficiales; las ubicaciones proceden del directorio registrado.

Criterio de aceptación. Para aprobar una evaluación factual, cada afirmación relevante debe poder contrastarse con el pasaje citado. Se deben rechazar o corregir contradicciones, atribuciones erróneas y fechas de otra columna de una tabla.

Alcance y limitaciones. El challenge confirma selección documental bajo sus criterios, pero no mide exhaustivamente fidelidad de texto generado. Se requiere complementar con una rúbrica humana para la respuesta final. El requisito expresa una propiedad de calidad, no otro botón de consulta.

Referencias de implementación. services/generation_verifier.py; services/rag_context.py; evidence/anexo-x-evaluacion-rag/resultado-original.json.

RNF-02 Abstención ante evidencia insuficiente

Prioridad Alta | **Estado** Implementado y evaluado en casos definidos

Explicación. Exige que el sistema reconozca cuándo no dispone de respaldo suficiente y evite completar la respuesta con hechos inventados. La abstención es un resultado válido del control de evidencia.

Aplicación en Catalina. El pipeline puede deshabilitar el contexto y devolver un mensaje controlado. La falta de sesión se trata aparte: pedir autenticación no equivale a haber evaluado y rechazado evidencia documental.

Criterio de aceptación. En una consulta negativa, el contexto debe permanecer deshabilitado y la respuesta final debe comunicar la insuficiencia sin citas fabricadas. Debe diferenciar no encontrar evidencia de afirmar que un servicio o hecho no existe.

Alcance y limitaciones. La corrida de 20 casos tuvo 10 negativos correctamente deshabilitados. Las capturas de aplicación muestran un caso final de abstención; son evidencias relacionadas, pero con unidades de evaluación distintas.

Referencias de implementación. services/answer_generation.py REJECTED_ANSWER_TEXT; scripts/evaluate_grounded_rag_challenge.py; evidencia de Figura 17.

RNF-03 Usabilidad de la interfaz

Prioridad Alta | **Estado** Verificación técnica parcial

Explicación. Busca que el usuario identifique cómo preguntar, enviar, consultar fuentes, cambiar de conversación y acceder al mapa sin una explicación técnica del sistema. Incluye mensajes de carga y error comprensibles.

Aplicación en Catalina. La interfaz ofrece chat compacto, modo ampliado, acciones con etiquetas, sugerencias, fuentes desplegables y temas claro y oscuro. El acceso a funciones restringidas se explica mediante solicitud de sesión.

Criterio de aceptación. El usuario debe poder completar tareas representativas con controles legibles y navegación coherente. La evaluación formal debería registrar éxito por tarea, errores y satisfacción de participantes.

Alcance y limitaciones. Se realizaron revisiones de interfaz y contraste, pero no se dispone aquí de un estudio formal de usuarios o una escala de usabilidad. La apariencia profesional y la preferencia del autor no bastan para demostrar usabilidad universal.

Referencias de implementación. frontend/web/src/App.tsx; frontend/web/src/theme.css; evidencia de verificaciones de interfaz.

RNF-04 Diseño responsivo

Prioridad Alta | **Estado** Implementado con verificación en tamaños concretos

Explicación. Permite que portada, chat, formularios y mapa adapten su distribución al espacio disponible. Su propósito es conservar lectura y operación en pantallas de escritorio y móviles.

Aplicación en Catalina. Las hojas de estilo ajustan tamaños y distribución; el menú y la vista del mapa disponen de comportamientos adaptados. La evaluación comprueba desbordamientos y acceso a controles.

Criterio de aceptación. En los tamaños de referencia, no debe existir desplazamiento horizontal no previsto ni controles esenciales fuera del área visible. Las fuentes deben poder leerse y el campo de consulta debe seguir siendo utilizable.

Alcance y limitaciones. Las verificaciones guardadas incluyen anchos de 390, 768 y 1440 píxeles sin desbordamiento horizontal. No constituyen una certificación para todos los dispositivos, navegadores o necesidades de accesibilidad.

Referencias de implementación. frontend/web/src/styles.css; theme.css; CampusMap.tsx; evidence/pruebas-2026-10-28/ui-portal.txt.

RNF-05 Protección de la información

Prioridad Alta | **Estado** Controles implementados con validación limitada

Explicación. Protege sesiones, operaciones administrativas e historial personal mediante autenticación, autorización y validación de entradas. Evita que el contenido de una pregunta sustituya un permiso del sistema.

Aplicación en Catalina. Catalina utiliza contraseñas con hash, tokens y renovación de sesión, comprobación de roles y propiedad de conversaciones. La API de ubicaciones requiere sesión y la administración requiere permisos. Existen controles de solicitudes y configuración de orígenes.

Criterio de aceptación. Sin credenciales válidas deben rechazarse recursos protegidos; un usuario sin rol administrativo no debe gestionarlos. Las respuestas no deben revelar contraseñas, tokens ni historial ajeno.

Alcance y limitaciones. Esto no representa una auditoría de seguridad integral ni garantiza cumplimiento normativo por sí solo. El túnel temporal publica la aplicación para pruebas y la portada conserva un plano orientativo; no se debe describir ese archivo como confidencial.

Referencias de implementación. security/passwords.py; services/auth.py; api/routes/auth.py; api/middleware; api/routes/campus.py.

RNF-06 Escalabilidad futura

Prioridad Media | **Estado** Preparación arquitectónica sin demostración de escala

Explicación. Plantea que el sistema pueda evolucionar en volumen de documentos, usuarios y consultas sin rehacer toda la aplicación. La escalabilidad debe distinguir crecimiento del corpus, concurrencia de peticiones e inferencia del modelo.

Aplicación en Catalina. La separación entre API, base relacional, índice vectorial e inferencia permite estudiar ampliaciones. Los trabajos de ingesta, la paginación y los límites de concurrencia son mecanismos útiles de partida.

Criterio de aceptación. Antes de aprobar una capacidad de escala concreta, se deben definir carga objetivo y límites y medir rendimiento, errores y consumo de recursos con concurrencia real.

Alcance y limitaciones. No se dispone de una prueba que demuestre un número específico de usuarios simultáneos ni autoescalado. La instalación actual en un servidor y la inferencia local pueden convertirse en cuellos de botella; la ampliación permanece como trabajo de evolución.

Referencias de implementación. services/chat.py control de concurrencia; db/postgres.py; arquitectura de servicios e ingesta.

RNF-07 Separación de componentes

Prioridad Alta | **Estado** Implementado en la organización del prototipo

Explicación. Exige responsabilidades distinguibles entre presentación, contratos API, reglas de servicio, persistencia, recuperación e inferencia. Facilita mantenimiento y pruebas de cambios localizados.

Aplicación en Catalina. React y TypeScript implementan la interfaz; FastAPI expone contratos; servicios y repositorios separan lógica y datos. PostgreSQL administra registros, Qdrant los vectores y Ollama la inferencia y los embeddings.

Criterio de aceptación. Los componentes deben intercambiar datos mediante contratos definidos y permitir pruebas aisladas de servicios. La interfaz no debe acceder directamente a credenciales de PostgreSQL o a la administración del índice.

Alcance y limitaciones. La separación lógica está presente, aunque los componentes puedan desplegarse en el mismo Debian. Esto no demuestra que todos sean microservicios independientes ni elimina acoplamientos o necesidades de refactorización.

Referencias de implementación. frontend/web/src/api.ts; api/routes; services; repositories; clients; db.

RNF-08 Trazabilidad documental

Prioridad Alta | **Estado** Implementado en backend con limitación en historial

Explicación. Permite relacionar un fragmento o respuesta con documento, versión y ejecución de indexación, y conservar página o sección cuando existen. Apoya auditoría y diagnóstico de actualizaciones del corpus.

Aplicación en Catalina. PostgreSQL registra documentos, versiones y ejecuciones; Qdrant conserva identificadores equivalentes en el payload. Las respuestas actuales incluyen citas con document_id, document_version_id, index_run_id y point_id.

Criterio de aceptación. Una fuente debe poder vincularse con su registro documental y ejecución sin confundir versiones. La ausencia de página en una fuente debe indicarse como dato no disponible, sin inventarla.

Alcance y limitaciones. El almacenamiento de citas detalladas en el historial recargado debe fortalecerse para sostener la misma trazabilidad en toda la experiencia. El JSON del challenge no serializa index_run_id por fuente, aunque otras evidencias sí lo incluyen.

Referencias de implementación. api/routes/answers.py SourceResponse; repositories/retrieval.py; esquemas de indexación y evidencia de recuperación.

RNF-09 Rendimiento y tiempo de respuesta

Prioridad Media | **Estado** Medición parcial sin garantía global

Explicación. Busca tiempos aceptables para recuperación y respuesta, con estados de carga que permitan comprender la espera. Debe medir por separado recuperación, generación, transporte y presentación.

Aplicación en Catalina. Se emplean rutas directas para casos inequívocos, extracción documental y otros mecanismos de reducción de trabajo. Ollama puede tardar considerablemente más cuando debe clasificar o generar texto.

Criterio de aceptación. Se deben definir objetivos por tipo de consulta y medir promedio, mediana, percentiles y errores en varias corridas. La pausa de presentación no debe contabilizarse como tiempo de generación del modelo.

Alcance y limitaciones. La corrida histórica registró 178,518 ms de media de recuperación; no mide respuesta completa. El frontend introduce una pausa visual mínima de 3, 5 o 9 segundos solicitada para la demostración; no garantiza un máximo de nueve segundos. Hubo consultas que superaron 60 segundos.

Referencias de implementación. services/chat.py; services/answer_generation.py; frontend/web/src/presentationPacing.ts; registros de evaluación.

RNF-10 Monitoreo del prototipo

Prioridad Media | Estado Implementado en API y registros operativos

Explicación. Permite conocer disponibilidad de dependencias, estados de trabajos, ejecuciones de indexación y métricas operativas. Su propósito es detectar fallos y facilitar el diagnóstico del prototipo.

Aplicación en Catalina. La API expone salud y preparación; el estado ready informa sobre PostgreSQL, Qdrant y Ollama. Rutas administrativas permiten consultar trabajos, ejecuciones y resúmenes de métricas. Los servicios registran estados, errores y tiempos.

Criterio de aceptación. Cuando una dependencia crítica no esté disponible, la verificación de preparación debe reflejarlo. Un trabajo debe poder consultarse por identificador y sus errores deben conservar un estado interpretable.

Alcance y limitaciones. La presencia de endpoints y registros no equivale a un sistema completo de alertas, paneles, retención y guardias de operación. No se identificó una consola visual de monitoreo integrada al frontend del usuario.

Referencias de implementación. api/routes/health.py; monitoring.py; metrics.py; services/monitoring.py; services/metrics.py.

Síntesis para el documento de grado

Catalina implementa el recorrido principal de consulta mediante lenguaje natural, recuperación de información, respuesta con fuentes, ubicación de dependencias e historial autenticado. El backend incluye operaciones para documentos, versiones, reindexación y monitoreo. Las categorías documentales y las preguntas frecuentes presentan un alcance parcial frente a una gestión administrativa completa.

Las condiciones no funcionales cuentan con mecanismos concretos y evidencias parciales. No corresponde afirmar que el prototipo garantiza exactitud factual absoluta, escalabilidad ilimitada o seguridad total. La evaluación técnica debe precisar el conjunto de consultas, las versiones documentales, el entorno y la capa medida.

Relación entre requerimientos

- RF-07 recupera evidencia y RF-08 la utiliza para elaborar una respuesta; RNF-01 evalúa su fundamentación y RNF-02 exige abstención cuando no hay respaldo.
- RF-09 muestra fuentes al usuario y RNF-08 mantiene su trazabilidad técnica. No son equivalentes: una fuente visible no prueba por sí sola persistencia completa de citas en el historial.
- RF-10, RF-11 y RF-12 mantienen el corpus. RNF-05 protege sus operaciones y RNF-10 permite observar su procesamiento.
- RF-05 identifica dependencias y RF-06 las representa en el plano; la orientación no garantiza requisitos, horarios ni acceso exacto.
- RNF-09 debe diferenciar el tiempo real del backend de la pausa visual configurada para la demostración.

Evidencias utilizadas

- Código del frontend React y de la API FastAPI revisado el 4 de noviembre de 2026, incluyendo contratos de consulta, directorio, documentos, trabajos y métricas.
- Resultado original del challenge RAG del 28 de octubre de 2026: 20 casos, evaluación de recuperación y habilitación de contexto. Archivo evidence/grounded-rag-challenge-2026-10-28/resultado-original.json.
- Evidencias de indexación, recuperación y respuesta con fuentes; archivos conservados en la carpeta evidence del espacio de trabajo.
- Verificaciones de interfaz del 28 de octubre y ensayos de calendario, sedes y PAW del 4 de noviembre; registros en evidence/video-demo.
- Las referencias de código y los criterios propuestos no se consideran pruebas ejecutadas por sí mismos. Para un acta de cumplimiento debe agregarse a cada requisito el caso de prueba, fecha, resultado y responsable.

Fuente de elaboración: revisión del prototipo Catalina y de sus evidencias técnicas, 2026.